



Assistant documentaire intelligent fondé sur une architecture RAG hybride

Exploitation du patrimoine documentaire du MINPMEESA en appui à la
production de l'Annuaire statistique et du Rapport annuel de performance

Documentation technique et fonctionnelle

Mémoire de Master 2 — Data Science et Modélisation Statistique (MDSMS)

Adnane MAMA IDISSA · ISSEA-CEMAC

Division des Études, des Projets et de la Prospective

1. Présentation générale

Le système est un **assistant documentaire intelligent** fondé sur une architecture **RAG hybride** (*Retrieval-Augmented Generation* — génération augmentée par récupération). Il interroge en langage naturel le patrimoine documentaire du MINPMEESA (Annuaire statistique, Notes de conjoncture, etc.) et restitue des réponses **sourcées**, avec une garantie forte sur les **données chiffrées** : elles sont reprises littéralement de la source, jamais recalculées.

Il répond à deux besoins :

- **Produire l'Annuaire statistique** — réunir et vérifier les informations dispersées dans les documents sources (mode *production*, agents) ;
- **Consulter les publications éditées** — accès rapide à une synthèse sourcée pour les décideurs (mode *consultation*).

2. Les outils et technologies utilisés

Le système est écrit en **Python 3** et n'utilise que des briques **libres, exécutables localement** — un choix dicté par l'exigence de **souveraineté** des données non publiées.

2.1 Traitement documentaire (ingestion)

Outil	Rôle dans le système	Pourquoi ce choix
PyMuPDF	Extraction du texte des PDF, avec position des blocs (lecture ordonnée des pages à deux colonnes)	Rapide, précis ; conserve les nombres près de leurs libellés
Expressions régulières	Nettoyage, détection des sommaires et des formulaires d'annexe vides, repérage des nombres	Léger, transparent, sans dépendance

L'ingestion découpe chaque document en **passages** (≈180 mots, avec recouvrement), en gardant les tableaux d'un seul tenant, et attache à chacun ses **métadonnées** : document, page, section, statut de diffusion (interne/publié), présence de chiffres et un **indice d'informativité** qui écarte les pages « creuses ».

2.2 Indexation et recherche

Outil	Rôle	Pourquoi ce choix
rank-bm25	Index lexical BM25 (mots-clés exacts)	Référence de la recherche d'information ; idéal pour un terme précis
scikit-learn (TF-IDF + SVD)	Index vectoriel de secours, 100 % hors-ligne (type LSA)	Signal sémantique sans aucun téléchargement de modèle
sentence-transformers / fastembed (<i>option</i>)	Index vectoriel de référence : encodeur multilingue (français)	Vraie recherche sémantique, exécutée localement
NumPy	Similarités cosinus (produit matriciel)	Recherche vectorielle exacte et instantanée à cette échelle

Deux canaux, une fusion. La recherche lexicale (mots) et la recherche sémantique (sens) sont complémentaires. Le système les combine par **Reciprocal Rank Fusion (RRF)**, méthode simple et robuste qui fusionne deux classements sans normaliser des scores d'échelles différentes.

2.3 Réordonnement (reranking)

Outil	Rôle	Pourquoi ce choix
cross-encoder (<i>option</i>)	Réévalue conjointement (question, passage) pour affiner le sommet des résultats	Plus précis sur les tout premiers rangs
Réordonneur « à traits » (interne)	Solution hors-ligne : couverture des termes, phrase exacte, concordance des nombres	Fonctionne sans modèle ; améliore la précision

2.4 Restitution et garde-fous

Composant	Rôle
Synthèse extractive (défaut)	Compose la réponse à partir de phrases reprises verbatim → aucune hallucination possible
Restitution par LLM local (<i>option</i>)	Rédaction par un modèle local (Ollama...), sous contrainte des garde-fous
Garde-fou numérique	Vérifie que chaque donnée chiffrée figure littéralement dans une source ; retire toute valeur non sourcée
Garde-fou de fidélité	Mesure la part des énoncés effectivement soutenus par les passages

2.5 Interface, évaluation, tests

Outil	Rôle
Streamlit	Application web (trois onglets, charte MINPMEESA, mise à jour de la documentation)
Module d'évaluation	nDCG@5, MRR, Precision@3, Recall@5 ; fidélité ; exactitude chiffrée ; cloisonnement ; validation des hypothèses
pytest	Tests automatiques (citation littéraire, cloisonnement, fusion RRF, métriques)

2.6 La chaîne de traitement

PDF → Ingestion (PyMuPDF, nettoyage, découpage, métadonnées)
→ Indexation (BM25 + vecteurs)
→ Recherche hybride (filtre de mode ► fusion RRF ► reranking)
→ Restitution sourcée (synthèse + garde-fous numérique & fidélité)
→ Interface (Interroger · Collecte Annuaire · Mise à jour)

3. Les fonctionnalités de l'application

L'application web s'ouvre en un clic (`demarrer.bat`) et présente **trois onglets**, plus une barre latérale de réglages.

3.1 Barre latérale — mode d'usage

- **Mode Production** (agents) : interroge tout le corpus (interne + publié).
- **Mode Consultation** (décideurs) : uniquement les documents publiés. Le **cloisonnement** est garanti : un document interne non validé est totalement inaccessible en consultation.

3.2 Onglet « Interroger »

- Question en langage naturel ; réponse composée de **passages sourcés**.
- Choix de l'étage de récupération (défaut : hybride + reranking) et filtres (type, année).
- **Contrôles qualité** : exactitude chiffrée, fidélité, nombre de sources.
- Passages sources dépliables, avec leur statut (interne / publié).

3.3 Onglet « Collecte pour l'Annuaire »

- Choix d'une **rubrique** de l'Annuaire (stock des PME, création, emploi, valeur ajoutée, trésorerie, conjoncture, inflation, appui aux PME).
- Réunit les **constats sourcés** et une colonne « **Données chiffrées** » ne conservant que les statistiques exploitables (pourcentages, effectifs), débarrassées des repères sans intérêt.

- **Export CSV ou Markdown** pour préparer les tableaux et commentaires de l'Annuaire.

3.4 Onglet « Mettre à jour la documentation »

- Liste des documents du corpus (titre, type, statut, année).
- **Ajouter / remplacer** un document (PDF + métadonnées) ou le **retirer**.
- **Reconstruire l'index** pour rendre les changements effectifs.
- Dépôt du **logo**, de la **bannière** et de la **couverture** de l'Annuaire.

3.5 Fonctionnalités transversales

- **Traçabilité** : chaque affirmation renvoie à sa source (document + page).
- **Citation littérale des chiffres** : garantie centrale du système.
- **Souveraineté** : fonctionnement entièrement local, sans envoi de données.
- **Deux populations d'utilisateurs** servies par le même index.

4. Utilisation en ligne de commande

```
python -m rag_minpmeesa.app.cli build                # construire l'index
python -m rag_minpmeesa.app.cli query "..." --mode production
python -m rag_minpmeesa.app.cli eval                 # évaluation (chapitre 4)
streamlit run rag_minpmeesa/app/streamlit_app.py     # interface web
```

5. Organisation des fichiers

```
rag_minpmeesa/
  config.py          paramètres, modes, seuils
  engine.py          moteur (point d'entrée)
  ingestion/         extraction, nettoyage, découpage, métadonnées
  index/             BM25 + vecteurs (backends enfichables)
  retrieval/         filtres, fusion RRF, reranking
  generation/        contexte, restitution, garde-fous (numérique, fidélité)
  evaluation/        métriques, jeu de test, protocole
  admin.py           gestion du corpus et des images
  collecte.py        rubriques de collecte pour l'Annuaire
  app/              interface CLI + application web Streamlit
data/ corpus · gold · results      docs/ documentation
tests/ tests automatiques
```

6. Notes de reproductibilité

- Sans accès réseau aux modèles pré-entraînés, le système bascule automatiquement sur ses **substituts hors-ligne** : tout reste fonctionnel.
- La **configuration de référence** (encodeur multilingue + cross-encodeur) améliore la recherche sémantique ; le protocole et les seuils restent identiques.
- Les hypothèses de **gain de temps** relèvent d'un protocole terrain auprès des agents et décideurs.

Document généré pour le mémoire — Assistant documentaire RAG du MINPMEESA · ISSEA-CEMAC.
