



Assistant documentaire intelligent fondé sur une architecture RAG hybride

Exploitation du patrimoine documentaire du MINPMEESA en appui à la
production de l'Annuaire statistique et du Rapport annuel de performance

Documentation technique et fonctionnelle

Mémoire de Master 2 — Data Science et Modélisation Statistique (MDSMS)

Adnane MAMA IDISSA · ISSEA-CEMAC

Division des Études, des Projets et de la Prospective

Sommaire

1. Présentation générale

2. Les outils et technologies utilisés

3. Les fonctionnalités de l'application

4. Aperçu de l'application

5. Utilisation en ligne de commande

6. Organisation des fichiers

7. Notes de reproductibilité

1. Présentation générale

Le système est un **assistant documentaire intelligent** fondé sur une architecture **RAG hybride** (*Retrieval-Augmented Generation* — génération augmentée par récupération). Il interroge en langage naturel le patrimoine documentaire du MINPMEESA (Annuaire statistique, Notes de conjoncture, etc.) et restitue des réponses **sourcées**, avec une garantie forte sur les **données chiffrées** : elles sont reprises littéralement de la source, jamais recalculées.

Il répond à deux besoins :

- **Produire l'Annuaire statistique** — réunir et vérifier les informations dispersées dans les documents sources (mode *production*, agents) ;
- **Consulter les publications éditées** — accès rapide à une synthèse sourcée pour les décideurs (mode *consultation*).

2. Les outils et technologies utilisés

Le système est écrit en **Python 3** et n'utilise que des briques **libres, exécutables localement** — un choix dicté par l'exigence de **souveraineté** des données non publiées.

2.1 Traitement documentaire (ingestion)

Outil	Rôle dans le système	Pourquoi ce choix
PyMuPDF	Extraction du texte des PDF, avec position des blocs (lecture ordonnée des pages à deux colonnes)	Rapide, précis ; conserve les nombres près de leurs libellés
Expressions régulières	Nettoyage, détection des sommaires et des formulaires d'annexe vides, repérage des nombres	Léger, transparent, sans dépendance

L'ingestion découpe chaque document en **passages** (≈180 mots, avec recouvrement), en gardant les tableaux d'un seul tenant, et attache à chacun ses **métadonnées** : document, page, section, statut de diffusion (interne/publié), présence de chiffres et un **indice d'informativité** qui écarte les pages « creuses ».

2.2 Indexation et recherche

Outil	Rôle	Pourquoi ce choix
rank-bm25	Index lexical BM25 (mots-clés exacts)	Référence de la recherche d'information ; idéal pour un terme précis
scikit-learn (TF-IDF + SVD)	Index vectoriel de secours, 100 % hors-ligne (type LSA)	Signal sémantique sans aucun téléchargement de modèle
sentence-transformers / fastembed (option)	Index vectoriel de référence : encodeur multilingue (français)	Vraie recherche sémantique, exécutée localement
NumPy	Similarités cosinus (produit matriciel)	Recherche vectorielle exacte et instantanée à cette échelle

Deux canaux, une fusion. La recherche lexicale (mots) et la recherche sémantique (sens) sont complémentaires. Le système les combine par **Reciprocal Rank Fusion (RRF)**, méthode simple et robuste qui fusionne deux classements sans normaliser des scores d'échelles différentes.

2.3 Réordonnement (reranking)

Outil	Rôle	Pourquoi ce choix
cross-encoder (option)	Réévalue conjointement (question, passage) pour affiner le sommet des résultats	Plus précis sur les tout premiers rangs
Réordonnanceur « à traits » (interne)	Solution hors-ligne : couverture des termes, phrase exacte, concordance des nombres	Fonctionne sans modèle ; améliore la précision

2.4 Restitution et garde-fous

Composant	Rôle
Synthèse extractive (défaut)	Compose la réponse à partir de phrases reprises verbatim → aucune hallucination possible
Restitution par LLM local (option)	Rédaction par un modèle local (Ollama...), sous contrainte des garde-fous
Garde-fou numérique	Vérifie que chaque donnée chiffrée figure littéralement dans une source ; retire toute valeur non sourcée
Garde-fou de fidélité	Mesure la part des énoncés effectivement soutenus par les passages

2.5 Interface, évaluation, tests

Outil	Rôle
Streamlit	Application web (trois onglets, charte MINPMEESA, mise à jour de la documentation)
Module d'évaluation	nDCG@5, MRR, Precision@3, Recall@5 ; fidélité ; exactitude chiffrée ; cloisonnement ; validation des hypothèses
pytest	Tests automatiques (citation littérale, cloisonnement, fusion RRF, métriques)

2.6 La chaîne de traitement

PDF → Ingestion (PyMuPDF, nettoyage, découpage, métadonnées)
→ Indexation (BM25 + vecteurs)
→ Recherche hybride (filtre de mode ▶ fusion RRF ▶ reranking)
→ Restitution sourcée (synthèse + garde-fous numérique & fidélité)
→ Interface (Interroger · Collecte Annuaire · Mise à jour)

3. Les fonctionnalités de l'application

L'application web s'ouvre en un clic (`demarrer.bat`) et présente **trois onglets**, plus une barre latérale de réglages.

3.1 Barre latérale — mode d'usage

- **Mode Production** (agents) : interroge tout le corpus (interne + publié).
- **Mode Consultation** (décideurs) : uniquement les documents publiés. Le **cloisonnement** est garanti : un document interne non validé est totalement inaccessible en consultation.

3.2 Onglet « Interroger »

- Question en langage naturel ; réponse composée de **passages sourcés**.
- Choix de l'étage de récupération (défaut : hybride + reranking) et filtres (type, année).
- **Contrôles qualité** : exactitude chiffrée, fidélité, nombre de sources.
- Passages sources dépliables, avec leur statut (interne / publié).

3.3 Onglet « Collecte pour l'Annuaire »

- Choix d'une **rubrique** de l'Annuaire (stock des PME, création, emploi, valeur ajoutée, trésorerie, conjoncture, inflation, appui aux PME).
- Réunit les **constats sourcés** et une colonne « **Données chiffrées** » ne conservant que les statistiques exploitables (pourcentages, effectifs), débarrassées des repères sans intérêt.
- **Export CSV ou Markdown** pour préparer les tableaux et commentaires de l'Annuaire.

3.4 Onglet « Mettre à jour la documentation »

- Liste des documents du corpus ; **ajout / remplacement / retrait** (PDF + métadonnées).
- **Reconstruction de l'index** ; dépôt du **logo**, de la **bannière** et de la **couverture**.

3.5 Fonctionnalités transversales

- **Traçabilité** : chaque affirmation renvoie à sa source (document + page).
- **Citation littérale des chiffres** ; **souveraineté** (tout en local) ; **deux populations d'utilisateurs** servies par le même index.

4. Aperçu de l'application

Captures d'écran de l'application, aux couleurs du MINPMEESA.

The screenshot displays the 'Assistant documentaire intelligent — MINPMEESA' interface. On the left, a sidebar shows the 'Mode d'usage' with 'Production (agents)' selected, and an 'Index' section. The main area features a header with the application title and a sub-header 'Interroger le patrimoine documentaire'. Below this, a search bar contains the question 'Quel est le nombre de PME estimé en 2023 ?'. A 'Récupération' dropdown is set to 'hybride+rerank'. A red 'Interroger' button is present. The 'Réponse' section shows two paragraphs of text, each followed by a citation: '[Annuaire statistique 2022 sur les PMEESA, p. 9-11]' and '[Annuaire statistique 2022 sur les PMEESA, p. 9]'. The interface is styled with green and white colors, consistent with the MINPMEESA branding.

Onglet « Interroger » (mode production) : réponse composée de passages sourcés, chaque affirmation renvoyant à son document et sa page.

Mode d'usage

Profil d'utilisateur ⓘ

Production (agents)

Consultation (décideurs)

PRODUCTION

Index

{ . . . }

Système RAG hybride · Mémoire M2

MDSMS · ISSEA-CEMAC

Deploy ⓘ

Assistant documentaire intelligent — MINPMEESA

Exploitation du patrimoine documentaire en appui à l'Annuaire statistique et au Rapport annuel de performance · Division des Études, des Projets et de la Prospective

Interroger

Collecte pour l'Annuaire

Mettre à jour la documentation

Collecte pour l'Annuaire statistique

Réunit, par rubrique, les constats et données chiffrées sourcés à transcrire dans l'Annuaire. Mode production (corpus complet).

Rubrique de l'Annuaire

Stock et structure des PME

Collecter cette rubrique

Collecter toutes les rubriques

Rubrique	Constat	Données chiffrées
Stock et structure des PME	Il apparaît dans cette 13ième édition de l'Annuaire Statistique sur les PMEESA que le :	393 954, 393 166, 97 %, 79,6
Stock et structure des PME	Le nombre d'entreprises en activité est estimé à 393 954 dont S'agissant de la création	393 954, 19 651, 54,53 %, 52
Stock et structure des PME	En termes de répartition par secteur d'activité, ces acteurs sont présents à 79,6% dan	79,6 %, 20,3 %, 0,1 %
Stock et structure des PME	Contribution des PME à l'économie Tableau 13 : Evolution de la Valeur Ajoutée des PM	255 059 287 376 288 850 324
Stock et structure des PME	Annexes Annexe 1: Couverture de l'enquête PME à enquêter PME ayant répondu au q	86.4 %, 4,8, 6,08, 7,85, 26,27
Stock et structure des PME	9 243 10 376 11 191 12 581 3,2 Nord-Ouest 12 772 18 105 18 197 20 428 22 033 24 769 €	9 243, 10 376, 11 191, 12 581

Exporter en CSV

Exporter en Markdown

Onglet « Collecte pour l'Annuaire » : constats et colonne « Données chiffrées » ne retenant que les statistiques exploitables, exportables en CSV / Markdown.

Mode d'usage

Profil d'utilisateur ?

Production (agents)

Consultation (décideurs)

PRODUCTION

Index

{...}

Système RAG hybride - Mémoire M2

MDSMS - ISSEA-CEMAC

Deploy

Assistent documentaire intelligent — MINPMEESA

Exploitation du patrimoine documentaire en appui à l'Annuaire statistique et au Rapport annuel de performance - Division des Études, des Projets et de la Prospective

Interroger

Collecte pour l'Annuaire

Mettre à jour la documentation

Mettre à jour la documentation

Ajoutez, remplacez ou retirez des documents, puis reconstruisez l'index pour les rendre interrogeables.

Documents du corpus

Annuaire statistique 2022 sur les PMEESA	annuaire_statistique	publié - 2022	
Note de conjoncture - 2e trimestre 2024	note_conjoncture	publié - 2024 T2	
Note de conjoncture - 3e trimestre 2024	note_conjoncture	publié - 2024 T3	
Note de conjoncture - 1er trimestre 2025	note_conjoncture	interne - 2025 T1	

Ajouter / remplacer un document

Fichier PDF

Upload

200MB per file • PDF

Onglet « Mettre à jour la documentation » : ajout / retrait de documents, reconstruction de l'index et dépôt des images de la structure.

5. Utilisation en ligne de commande

```
python -m rag_minpmeesa.app.cli build # construire l'index
python -m rag_minpmeesa.app.cli query "." --mode production
python -m rag_minpmeesa.app.cli eval # évaluation (chapitre 4)
streamlit run rag_minpmeesa/app/streamlit_app.py # interface web
```

Assistent documentaire RAG — MINPMEESA

Page 8 / 9

6. Organisation des fichiers

```
rag_minpmeesa/  
  config.py          paramètres, modes, seuils  
  engine.py          moteur (point d'entrée)  
  ingestion/         extraction, nettoyage, découpage, métadonnées  
  index/             BM25 + vecteurs (backends enfichables)  
  retrieval/         filtres, fusion RRF, reranking  
  generation/        contexte, restitution, garde-fous (numérique, fidélité)  
  evaluation/        métriques, jeu de test, protocole  
  admin.py           gestion du corpus et des images  
  collecte.py        rubriques de collecte pour l'Annuaire  
  app/               interface CLI + application web Streamlit  
data/  corpus · gold · results          docs/  documentation  
tests/  tests automatiques
```

7. Notes de reproductibilité

- Sans accès réseau aux modèles pré-entraînés, le système bascule automatiquement sur ses **substituts hors-ligne** : tout reste fonctionnel.
- La **configuration de référence** (encodeur multilingue + cross-encodeur) améliore la recherche sémantique ; le protocole et les seuils restent identiques.
- Les hypothèses de **gain de temps** relèvent d'un protocole terrain auprès des agents et décideurs.

Document généré pour le mémoire — Assistant documentaire RAG du MINPMEESA · ISSEA-CEMAC.
